
LAPORAN TUGAS

Pemrosesan Bahasa Alami Lanjut

Supervised Fine-Tuning (SFT) pada Small Language Model
menggunakan LoRA

Disusun oleh:

Bruri Wijayanto

NIM: 25/568904/PPA/07156

1. Pendahuluan

1.1 Latar Belakang

Large Language Model (LLM) yang dilatih secara self-supervised memiliki pengetahuan dunia yang luas. Namun model tersebut pada dasarnya hanya belajar memprediksi token berikutnya dari teks, bukan untuk merespons instruksi. Akibatnya, base model sering menunjukkan perilaku yang tidak sesuai harapan ketika diberikan instruksi langsung.

Supervised Fine-Tuning (SFT) adalah tahap pertama dalam proses alignment: model dilatih ulang pada pasangan (instruksi, respons) berkualitas tinggi sehingga belajar berbicara layaknya asisten yang kooperatif. Tugas ini membangun proses tersebut dari nol menggunakan teknik efisiensi LoRA (Low-Rank Adaptation).

1.2 Tujuan

- Menjelaskan perbedaan perilaku base model dan instruction-tuned model
- Memuat dan memformat dataset instruksi dalam bentuk chat template
- Mengonfigurasi dan menjalankan SFT menggunakan SFTTrainer dari library TRL
- Mengimplementasikan LoRA sebagai metode efisiensi parameter (PEFT)
- Mengevaluasi hasil fine-tuning secara kualitatif melalui prompt uji

1.3 Spesifikasi Teknis

Komponen	Detail
Model	TinyLlama/TinyLlama-1.1B-Chat-v1.0
Ukuran Model	1.1 Miliar parameter
Dataset	Sintetis buatan sendiri 42 contoh bahasa daerah & budaya Nusantara
Platform	Google Colab
GPU	Tesla T4 (15.6 GB VRAM)
Framework	transformers==4.44.0, peft==0.12.0, trl==0.10.1
LoRA Config	r=16, alpha=32, dropout=0.05, 7 target modules
Training	10 epoch, batch efektif=2, lr=2e-4, 180 total steps

2. Dataset

2.1 Deskripsi Dataset

Dataset yang digunakan adalah dataset sintetis buatan sendiri yang terdiri dari 42 contoh instruksi tentang bahasa daerah dan budaya Nusantara Indonesia. Dataset ini dibuat untuk memenuhi kriteria bonus +10% pada rubrik penilaian yang mensyaratkan originalitas dan relevansi budaya.

Aspek	Detail
Jumlah contoh total	42 contoh
Split training	37 contoh (90%)
Split evaluasi	5 contoh (10%)
Format	Chat template: user / assistant
Bahasa output	Bahasa Indonesia

2.2 Topik yang Dicakup

- Adat & tradisi Jawa (filosofi Memayu Hayuning Bawana, Ojo Dumeh, Nrimo ing Pandum, Sekaten)
- Adat & tradisi Sunda (Seren Taun, pamali, Silih Asah Silih Asih Silih Asuh)
- Adat & tradisi Batak (Dalihan Na Tolu, Mangulosi, Marsipature Hutana Be)
- Adat & tradisi Bali (Subak, Nyepi, Tri Hita Karana, tari Kecak)
- Filosofi Bugis (Siri Na Pacce) dan budaya Betawi (Si Pitung)
- Kuliner Nusantara (rendang, gudeg, opor ayam, sate Madura)
- Cerita rakyat (Sangkuriang, Danau Toba, Malin Kundang)
- Terjemahan bahasa daerah (Jawa Krama, Sunda, Bali)

2.3 Contoh Format Data

```
{
  "instruction": "Apa makna filosofi Jawa 'Memayu Hayuning Bawana'?",
  "input": "",
  "output": "Memayu Hayuning Bawana adalah filosofi Jawa yang berarti 'memperindah keindahan dunia'..."
}
```

3. Metodologi

3.1 Arsitektur LoRA

LoRA (Low-Rank Adaptation) menambahkan matriks berdimensi rendah pada layer tertentu sehingga hanya sebagian kecil parameter yang dilatih. Secara matematis, update bobot didekomposisi sebagai:

$$W' = W + \Delta W = W + (\alpha/r) \cdot B \cdot A$$

di mana:

$B \in \mathbb{R}^{(d \times r)}$ matriks kiri (diinisialisasi nol)
 $A \in \mathbb{R}^{(r \times k)}$ matriks kanan (diinisialisasi random)
 $r = 16$ rank (jauh lebih kecil dari d dan k)
 $\alpha = 32$ skala ($2 \times$ rank)

Bobot asli W dibekukan (frozen) selama training. Hanya B dan A yang dilatih, sehingga jumlah parameter yang perlu dioptimasi sangat kecil.

3.2 Konfigurasi LoRA

Parameter	Nilai
Rank (r)	16
Alpha (α)	32
Dropout	0.05
Target modules	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
Task type	CAUSAL_LM
Bias	none

3.3 Konfigurasi Training

Parameter	Nilai
Num epochs	10
Batch size per device	1
Gradient accumulation steps	2
Efektif batch size	2
Learning rate	$2e-4$
LR scheduler	cosine
Warmup ratio	0.05
Weight decay	0.01

Max sequence length	512
FP16	True (GPU)
Gradient checkpointing	True
Total steps	180

4. Hasil Eksperimen

4.1 Statistik Parameter LoRA

Kategori	Jumlah Parameter (%)
Dapat dilatih (LoRA)	12.615.680 (1,13%)
Frozen (base model)	1.100.048.384 (98,87%)
Total	1.112.664.064 (100%)
Ukuran adapter tersimpan	52,9 MB (vs. 2,2 GB full model)

4.2 Training Loss per Epoch

Epoch	Train Loss	Eval Loss	Status
0	2,1576	1,9310	Normal
2	1,3430	2,0241	Eval mulai naik
4	0,5960	2,4098	X Overfitting
6	0,2255	2,7681	X X Parah
8	0,0747	2,8590	X X X Sangat parah
9	0,1061	2,8677	X X X Sangat parah

Catatan: Teks merah pada kolom Eval Loss menunjukkan tren overfitting. Epoch terbaik berdasarkan eval loss adalah epoch 0 (1,9310). Train loss turun drastis dari 2,16 ke 0,07 menunjukkan model menghafal data training, bukan belajar pola umum.

4.3 Evaluasi Kualitatif

Berikut perbandingan respons base model vs model fine-tuned pada 3 prompt uji representatif:

Prompt 1: Jelaskan makna filosofi Bugis 'Siri Na Pacce'...

Model	Respons (cuplikan)
Base Model	"...adalah ilustrasi dari perangkat lunak yang paling terbuka..." tidak relevan, menyebut perangkat lunak
Fine-tuned	"Siri Na Pacce adalah filosofi yang mencerminkan...pemikiran, kegiatan dan pendidikan..." mulai menyebut konteks budaya meski belum akurat

Prompt 2: Apa perbedaan antara wayang kulit dan wayang golek?

Model	Respons (cuplikan)
Base Model	"Wayang kulit merupakan desain atau bahan kerja untuk memotifkan gambar..." definisi sama sekali salah
Fine-tuned	"Wayang kulit adalah genre yang digunakan untuk menggambarkan ilustrasi..." masih kurang akurat tapi mencoba konteks seni

Prompt 3: Bagaimana cara membuat opor ayam?

Model	Respons (cuplikan)
Base Model	"Opor ayam adalah produk yang menggunakan jerawat atau masakan..." halusinasi parah
Fine-tuned	"Membuat opor ayam, tidak ada bahan sing urut. Ayam merupakan daun..." konteks memasak muncul, tapi masih kacau dan ada kata Bali bocor (inggih)

Secara umum fine-tuning berhasil menggeser model dari mode 'text completion' ke mode 'instruction following'. Perubahan paling nyata: model fine-tuned konsisten menjawab dalam bahasa Indonesia, sedangkan base model sering mencampur bahasa Inggris. Namun akurasi konten masih rendah akibat overfitting yang terdokumentasi.

5. Pertanyaan Analisis

Q1. Mengapa base model memiliki pengetahuan luas tetapi lemah dalam mengikuti instruksi?

Selama pre-training, base model dilatih dengan fungsi loss next-token prediction (Causal Language Modeling):

$$L_{\text{pre-train}} = - \sum \log P(x_t \mid x_1, x_2, \dots, x_{t-1}; \theta)$$

Model belajar memprediksi token berikutnya dari seluruh teks internet tanpa pernah diajarkan perbedaan antara instruksi dan jawaban. Dari sudut pandang loss ini, kalimat 'Apa itu rendang?' dan 'Rendang adalah masakan Padang...' diperlakukan setara keduanya hanya rangkaian token yang harus diprediksi.

Akibatnya, ketika diberi instruksi, base model cenderung:

- Melanjutkan teks alih-alih menjawab, karena training objective-nya memang melanjutkan token
- Tidak mengenali format percakapan user/assistant
- Menghasilkan output tidak relevan terbukti pada eksperimen ini, base model menjawab pertanyaan wayang kulit dengan mendeskripsikannya sebagai 'desain atau bahan kerja untuk memotifkan gambar'

SFT memperbaiki ini dengan mengubah distribusi data latih ke pasangan (instruksi, respons), dan loss hanya dihitung pada token respons asisten memaksa model belajar: saat ada instruksi, berikan jawaban yang relevan dan berhenti.

Q2. Berapa persen parameter yang dilatih dengan LoRA? Apa dampaknya terhadap efisiensi?

Dari output eksperimen, LoRA hanya melatih 12.615.680 parameter dari total 1.112.664.064 setara dengan 1,13%.

Parameter LoRA yang dilatih	:	12.615.680	(1,13%)
Parameter frozen	:	1.100.048.384	(98,87%)
Total	:	1.112.664.064	(100%)

Cara kerja LoRA: alih-alih memperbarui bobot W langsung (yang memerlukan melatih $d \times k$ parameter), LoRA mendekomposisi update menjadi dua matriks kecil B dan A dengan rank $r=16$. Ini jauh lebih kecil dari dimensi asli layer attention TinyLlama.

Dampak efisiensi yang terukur dari eksperimen ini:

Aspek	Full Fine-tuning (estimasi)	LoRA r=16 (eksperimen ini)
Parameter dilatih	~1,1B (100%)	12,6M (1,13%)
Ukuran checkpoint	~2,2 GB	52,9 MB
Waktu training	Sangat lama	154,5 detik
Catastrophic forgetting	Risiko tinggi	Risiko rendah

Penghematan ukuran storage lebih dari 97%: adapter LoRA hanya 52,9 MB dibanding model penuh yang 2,2 GB. Ini sangat menguntungkan untuk deployment, berbagi model, dan menjalankan beberapa adapter berbeda di atas satu base model yang sama.

Q3. Tampilkan 3 contoh respons sebelum dan sesudah fine-tuning. Analisis perbedaannya.

Tiga prompt representatif berikut menggambarkan perubahan perilaku model setelah SFT:

Prompt	Base Model	Fine-tuned	Analisis
Siri Na Pacce	Menyebut perangkat lunak tidak relevan sama sekali	Mencoba konteks budaya meski masih kurang akurat	Format membaik, domain mulai dikenali
Wayang kulit vs golek	Mendeskripsikan sebagai bahan kerja / motif gambar	Mencoba mendeskripsikan sebagai seni, tapi konten masih salah	Bahasa Indonesia konsisten, domain seni mulai muncul
Opor ayam	Menyebut 'jerawat' dalam bahan masakan halusinasi parah	Konteks memasak muncul, tapi ada kata Bali (inggih) yang bocor dari dataset	Improvement nyata, tapi overfitting menyebabkan kebocoran kata dari data lain

Kesimpulan analisis: fine-tuning berhasil menggeser model dari mode 'text completion' ke 'instruction following'. Perubahan paling nyata adalah konsistensi penggunaan bahasa Indonesia. Namun akurasi konten masih rendah karena overfitting pada dataset yang terlalu kecil (37 contoh training).

Q4. Apa risiko overfitting pada dataset kecil? Bagaimana mendeteksi dan mencegahnya?

Overfitting terjadi dalam eksperimen ini dan terdokumentasi dengan sangat jelas dari tabel loss:

Epoch	Train Loss	Eval Loss	Interpretasi
0	2,1576	1,9310 ✓	Model belajar normal
2	1,3430	2,0241 ↑	Eval mulai naik tanda awal overfitting
4	0,5960	2,4098 ↑↑	Overfitting terkonfirmasi
6	0,2255	2,7681 ↑↑↑	Overfitting parah
8	0,0747	2,8590 ↑↑↑	Model hampir menghafal semua data training
9	0,1061	2,8677 ↑↑↑	Epoch terbaik seharusnya dihentikan di epoch 0

Penyebab utama: dengan hanya 37 contoh training, model 1,1B parameter memiliki kapasitas yang jauh lebih besar dari yang dibutuhkan untuk menghafal seluruh dataset sehingga ia menghafal alih-alih belajar pola umum.

Cara mendeteksi: dari grafik training curve, saat train loss terus turun tapi eval loss naik ini sinyal overfitting. Dalam kasus ini, titik terbaik adalah epoch 0 dengan eval loss 1,9310.

Cara mencegah untuk eksperimen berikutnya:

- Tambah data gunakan dataset HuggingFace seperti bryandts (282K contoh) atau NusaX-MT
- Early stopping hentikan training saat eval loss mulai naik (epoch 1 dalam kasus ini)
- Kurangi epoch cukup 1-2 epoch untuk dataset sangat kecil
- Naikkan dropout dari lora_dropout=0.05 ke 0.1 untuk regularisasi lebih kuat
- Perkecil rank LoRA dari r=16 ke r=4 untuk kapasitas model yang lebih ketat
- Naikkan weight_decay dari 0.01 ke 0.05

Q5. (Bonus) Tantangan dalam membuat dataset bahasa daerah berkualitas tinggi

Dalam pembuatan 42 contoh dataset sintetis bahasa daerah dan budaya Nusantara, terdapat beberapa tantangan nyata yang dihadapi:

1. Verifikasi keakuratan informasi budaya

Filosofi seperti Dalihan Na Tolu (Batak) atau Tri Hita Karana (Bali) memiliki nuansa yang mudah disederhanakan berlebihan. Diperlukan riset dari sumber yang otoritatif tidak bisa hanya mengandalkan pengetahuan umum.

2. Variasi linguistik bahasa daerah yang kompleks

Bahasa Jawa punya tingkatan Ngoko-Madya-Krama-Krama Inggil, bahasa Sunda punya undak-usuk basa. Membuat contoh terjemahan yang benar membutuhkan kompetensi penutur asli. Hal ini terbukti dari hasil evaluasi model fine-tuned bocor menggunakan kata bahasa Bali (inggih) saat menjawab pertanyaan tentang opor ayam, karena distribusi data latih tidak seimbang.

3. Keseimbangan representasi suku

Tanpa kesadaran penuh, dataset mudah condong ke budaya Jawa (mayoritas) dan mengabaikan bahasa daerah dari luar Jawa Batak, Bugis, Maluku, Papua yang justru lebih low-resource dan lebih membutuhkan representasi dalam NLP.

4. Kualitas vs kuantitas

42 contoh berkualitas tinggi lebih baik untuk SFT daripada ratusan contoh generik. Namun kuantitas kecil terbukti menyebabkan overfitting parah seperti yang terlihat di eksperimen ini trade-off yang nyata dan tidak mudah dihindari tanpa sumber daya yang memadai.

Yang dipelajari: membuat dataset instruksi berbasis kearifan lokal bukan sekadar masalah teknis ia membutuhkan sensitivitas budaya dan idealnya validasi dari penutur asli komunitas tersebut. Hasil eksperimen ini, meski belum sempurna, adalah langkah kecil yang nyata menuju low-resource NLP untuk bahasa daerah Indonesia.

6. Kesimpulan

Eksperimen SFT dengan LoRA pada TinyLlama-1.1B-Chat menggunakan dataset bahasa daerah Indonesia menghasilkan beberapa temuan kunci:

1. LoRA berhasil mereduksi parameter yang perlu dilatih dari 1,1B menjadi hanya 12,6M (1,13%), dengan adapter yang hanya berukuran 52,9 MB. Ini membuktikan efisiensi luar biasa PEFT dibanding full fine-tuning.
2. Fine-tuning berhasil menggeser perilaku model dari mode 'text completion' ke 'instruction following'. Perubahan paling nyata adalah konsistensi penggunaan bahasa Indonesia dalam respons.
3. Overfitting terjadi mulai epoch ke-2 akibat dataset yang terlalu kecil (37 contoh training). Train loss turun ke 0,07 sementara eval loss naik ke 2,87 selisih yang sangat besar dan menjadi pelajaran penting tentang pentingnya ukuran dataset dalam SFT.
4. Pembuatan dataset bahasa daerah adalah tantangan tersendiri yang membutuhkan kompetensi budaya dan linguistik, bukan hanya kemampuan teknis.

Untuk eksperimen lanjutan, direkomendasikan menggunakan dataset HuggingFace seperti bryandts (282K contoh, 9 bahasa daerah) dengan 1-2 epoch, early stopping, dan LoRA rank yang lebih kecil ($r=4$) untuk menghindari overfitting.

7. Referensi

- Hu et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685
- Ouyang et al. (2022). Training language models to follow instructions with human feedback (InstructGPT). NeurIPS 2022.
- Cahyawijaya et al. (2023). Cendol: Open Instruction-tuned Generative Large Language Models for Indonesian Languages. ACL 2024.
- Winata et al. (2023). NusaX: Multilingual Parallel Sentiment Dataset for 10 Indonesian Local Languages. EACL 2023.
- TRL SFTTrainer Documentation: https://huggingface.co/docs/trl/sft_trainer
- PEFT / LoRA Documentation: <https://huggingface.co/docs/peft>
- Dataset bryandts: <https://huggingface.co/datasets/bryandts/instruction-dataset-indo-java-sunda-bali-gayo-batak-alas-minang-betawi>